



GUÍA DE USUARIO

DOCUMENT PROCESSOR

Sistema de análisis y aprendizaje documental

Manual integral para operación pública, administración e integración API

Versión 1.0 | Agosto de 2026

Control documental

Este manual describe la versión desplegada de Document Processor en AWS EC2 y debe actualizarse cuando cambien los flujos visibles, los permisos o los endpoints públicos.

Elemento	Valor
Documento	Manual de usuario de Document Processor
Versión	1.0
Fecha	25 de agosto de 2026
Estado	Vigente
Cobertura	Analizador público, consola administrativa e integración API
Entorno verificado	AWS EC2 - despliegue productivo

Tabla P.1. Control del documento.

NOTA	Las capturas reflejan el entorno disponible durante la elaboración. Los datos operativos pueden cambiar sin alterar el procedimiento general.
-------------	---

Público objetivo

- Personal que carga documentos y consulta resultados de extracción.
- Personal administrador que configura tipos, campos, plantillas, anotaciones, lotes y modelos.
- Personal técnico que integra sistemas mediante API key.

Siglas y acrónimos

Sigla	Significado
API	Interfaz de programación de aplicaciones
EC2	Elastic Compute Cloud de Amazon Web Services
JSON	Notación de objetos de JavaScript
NLP	Procesamiento de lenguaje natural
OCR	Reconocimiento óptico de caracteres
PDF	Formato de documento portátil
REST	Estilo de arquitectura para servicios web
spaCy	Biblioteca de procesamiento de lenguaje natural utilizada por el sistema

Tabla P.2. Siglas utilizadas en el manual.

ÍNDICE DE FIGURAS

Figura 2.1. Acceso administrativo	2
Figura 2.2. Consola documental	3
Figura 3.1. Analizador público	4
Figura 4.1. Asistente de tipo documental	6
Figura 4.2. Campos documentales	7
Figura 5.1. Plantilla aprendida	8
Figura 5.2. Anotación asistida	9
Figura 6.1. Lotes de entrenamiento	10
Figura 6.2. Versiones de modelo	11
Figura 7.1. Conexión API	12

ÍNDICE DE TABLAS

Tabla 1.1. Perfiles de uso	1
Tabla 2.1. Elementos de la consola	3
Tabla 3.1. Campos del analizador	4
Tabla 4.1. Datos de un campo documental	7
Tabla 5.1. Métodos de preprocesamiento	9
Tabla 6.1. Etapas del aprendizaje	10
Tabla 7.1. Endpoints de integración	13
Tabla 8.1. Solución de problemas	14

ÍNDICE GENERAL

1	Introducción al sistema	1
2	Acceso, perfiles y navegación	2
3	Analizador público	4
4	Tipos documentales y campos	6
5	Plantillas y anotación asistida	8
6	Aprendizaje, lotes y modelos	10
7	Claves e integración API	12
8	Solución de problemas y buenas prácticas	14
9	Glosario y referencias	15

1

Introducción al sistema

Document Processor es una plataforma para cargar archivos PDF, extraer datos mediante OCR y modelos NLP, y mejorar gradualmente la extracción con plantillas, anotaciones y documentos validados.

1.1 Objetivo

El sistema reduce la captura manual y centraliza el ciclo que va desde la definición de un tipo documental hasta la publicación de un modelo evaluado. La extracción pública y la administración comparten el mismo catálogo de tipos documentales.

1.2 Perfiles de uso

Perfil	Responsabilidad	Acceso
Usuario del analizador	Seleccionar un tipo, cargar un PDF y revisar la extracción.	Analizador público
Administrador	Configurar documentos, campos, plantillas, anotaciones, lotes, modelos y claves.	Inicio de sesión
Integrador API	Enviar PDFs y correcciones desde otro sistema.	API key

Tabla 1.1. Perfiles de uso del sistema.

1.3 Flujo general

1. **Definir el documento.** El administrador registra el tipo documental y su estado.
2. **Configurar campos.** Se especifican nombres, claves, etiquetas y obligatoriedad.
3. **Crear evidencia.** Una plantilla o anotaciones relacionan valores reales con el OCR.
4. **Extraer y validar.** El analizador o un sistema externo envía documentos y correcciones.
5. **Entrenar y evaluar.** Los lotes generan candidatos que se comparan antes de activarse.

IMPORTANTE

La calidad del modelo depende de que los campos y las correcciones representen exactamente el contenido visible del PDF.

2 Acceso, perfiles y navegación

La consola administrativa concentra la configuración y la supervisión. El analizador permanece disponible sin sesión para los flujos de carga autorizados por la operación.

2.1 Ingreso administrativo

Abra la ruta `/admin`. Si no existe una sesión activa, el sistema mostrará el formulario de acceso, como se observa en la Figura 2.1.

The image shows a login form titled "Consola documental" with the subtitle "Ingresa para administrar tipos documentales, plantillas, aprendizaje y modelos." It contains two input fields: "Usuario" and "Contraseña". Below the fields is a blue button labeled "Entrar". At the bottom, there is a link that says "Ir al analizador publico".

Figura 2.1. Formulario de acceso a la consola administrativa.

6. **Escriba el usuario administrativo.** Utilice la credencial vigente definida por la operación.
7. **Escriba la contraseña.** El campo oculta los caracteres introducidos.
8. **Seleccione Entrar.** El sistema valida la credencial y abre la consola.

ADVERTENCIA

No incluya credenciales administrativas ni API keys en capturas, tickets, repositorios o ejemplos compartidos.

2.2 Consola documental

Después del acceso se muestra el documento seleccionado, sus indicadores y el menú de siete etapas, como se observa en la Figura 2.2.




Figura 2.2. Vista general de la consola documental.

Elemento	Función
Documento	Lista, selecciona y crea tipos documentales.
Campos	Define los datos que debe extraer el sistema.
Plantilla	Aprende posiciones y contexto desde un PDF validado.
Anotación	Relaciona fragmentos exactos del OCR con un campo.
Aprendizaje	Muestra lotes y permite iniciar entrenamiento.
Modelos	Registra, compara y activa versiones.
API	Genera claves y ejemplos de integración.

Tabla 2.1. Elementos principales de la consola.

2.3 Selección del tipo documental

Las acciones directas de cada tarjeta abren la etapa correspondiente sin cambiar de tipo. Verifique siempre el nombre, estado y modelo mostrados en el encabezado antes de editar.

3 | Analizador público

El analizador recibe un archivo PDF, muestra su vista previa y presenta los valores extraídos para el tipo documental seleccionado.

3.1 Pantalla de análisis

Al ingresar a `/analizador` se muestran la zona de vista previa y el formulario de extracción, como se observa en la Figura 3.1.

Figura 3.1. Analizador público de documentos PDF.

Campo	Descripción
Tipo de documento	Catálogo activo que determina campos, plantilla, preprocesamiento y modelo.
Archivo PDF	Documento que se previsualizará y enviará para extracción.
Analizar documento	Inicia OCR, predicción y construcción de la respuesta.

Tabla 3.1. Campos y acción del analizador.

3.2 Analizar un documento

9. **Seleccione el tipo documental.** Use el nombre que corresponda al formato del archivo.
10. **Seleccione Archivo PDF.** Elija un archivo legible y no protegido.
11. **Revise la vista previa.** Confirme que el documento correcto aparezca en el panel izquierdo.
12. **Seleccione Analizar documento.** Espere a que finalice el procesamiento.
13. **Revise los datos extraídos.** Preste especial atención a campos obligatorios o con baja confianza.

NOTA

Un valor ausente no debe inventarse. Debe corregirse en el sistema consumidor y enviarse como

documento validado para aprendizaje cuando aplique.

3.3 Recomendaciones para el PDF

- Utilice páginas derechas, completas y con resolución suficiente.
- Evite sombras, recortes, reflejos y texto cubierto por sellos.
- Seleccione el tipo documental antes de iniciar el análisis.

4 Tipos documentales y campos

La configuración documental establece qué formatos reconoce el sistema y qué información debe obtener de cada uno.

4.1 Crear un tipo documental

En la etapa Documento, seleccione Crear tipo documental. El asistente solicita la información en pasos y muestra el formulario de la Figura 4.1.

The screenshot displays the 'Consola documental' interface. On the left is a sidebar with a menu including 'Documento', 'Campos', 'Plantilla', 'Anotacion', 'Aprendizaje', 'Modelos', and 'API'. The main area shows a 'Constancia de servicio' document type, which is active. Below it, a modal titled 'Crear tipo documental' is open, prompting the user to complete a document type. The modal has a 'Nombre' field with the placeholder 'Ficha de pago' and a 'Continuar' button. In the background, a list of document types is visible, each with a 'borrador' (draft) status and buttons for 'Ver', 'Campos', 'Plantilla', 'Anotar', 'Aprendizaje', and 'Modelos'. The document types listed are 'Constancia de servicio', 'Ficha de pago', 'INE', 'Licencia', and 'Licencia'.

Figura 4.1. Asistente para crear un tipo documental.

14. **Capture el nombre.** Utilice una denominación clara para la persona usuaria.
15. **Capture la descripción.** Explique el origen y propósito del formato.
16. **Defina el estado.** Use Borrador mientras la configuración no esté validada.
17. **Revise el modelo inicial.** Mantenga la ruta o nombre autorizado por la operación.
18. **Confirme la creación.** El nuevo tipo aparecerá en la lista documental.

IMPORTANTE

No active un tipo documental hasta configurar y probar sus campos con documentos representativos.

4.2 Configurar campos

La etapa Campos muestra la definición actual y el formulario de alta, como se observa en la Figura 4.2.

Consola documental

Panel administrativo para definir documentos, revisar evidencias y controlar modelos OCR/NLP.

Abrir analizador publico

Cerrar sesion

01 Documento

02 Campos

03 Plantilla

04 Anotacion

05 Aprendizaje

06 Modelos

07 API

Constancia de servicio

Documento academico usado por la version inicial del sistema.

Estado: activo

Modelo: spacy_model

Campos

6

Documentos OCR

0

Lotes

0

Ultima decision

-

Vista Campos abierta.

Campos obligatorios y opcionales

Matricula

alu_matricula - texto

MATRICULA

Nombre

alu_nombre - texto

NOMBRE

Apellido paterno

alu_apaterno - texto

PATERNO

Apellido materno

alu_amaterno - texto

MATERNO

Carrera

alu_carrera - texto

CARRERA

Servicio

alu_servicio - texto

SERVICIO

Nombre

Matricula

Clave

alu_matricula

Etiqueta spaCy

MATRICULA

Tipo

Texto

☐

Campo obligatorio

Descripcion

Agregar campo

Vista Formas abierta.

Campo obligatorio

Descripcion

Agregar campo

Vista Campos abierta.

Figura 4.2. Configuración de campos obligatorios y opcionales.

Dato	Uso	Ejemplo
Nombre	Etiqueta visible para la persona administradora.	Matrícula
Clave	Identificador estable utilizado en JSON e integraciones.	alu_matricula
Etiqueta spaCy	Nombre de la entidad utilizada en entrenamiento.	MATRICULA
Tipo	Tratamiento esperado del valor.	texto, fecha o catálogo
Obligatorio	Determina si una validación puede aceptarse sin el campo.	Sí/No
Descripción	Regla o contexto de captura.	Número de control escolar

Tabla 4.1. Datos de configuración de un campo documental.

4.3 Convenciones

- No cambie una clave después de integrarla con sistemas externos.
- Use etiquetas spaCy en mayúsculas y sin espacios.
- Marque como obligatorio solo aquello que siempre está presente y debe validarse.

5 Plantillas y anotación asistida

Las plantillas aprovechan la estructura repetible de un formato; las anotaciones aportan ejemplos precisos para el entrenamiento por entidades.

5.1 Crear una plantilla

Seleccione Plantilla para cargar un primer PDF validado y proporcionar sus valores reales. La pantalla se muestra en la Figura 5.1.

Figura 5.1. Formulario para crear una plantilla desde OCR.

19. **Escriba un nombre de plantilla.** Identifique la versión o procedencia del formato.
20. **Seleccione el PDF de referencia.** Utilice un ejemplo completo y legible.
21. **Capture los valores en JSON.** Use las claves configuradas y los valores exactos del documento.
22. **Seleccione Crear plantilla desde OCR.** El sistema localizará texto, posiciones y contexto.

ADVERTENCIA

Un valor JSON que no coincide con el PDF puede producir una plantilla incorrecta y degradar extracciones posteriores.

5.2 Anotación asistida

La etapa Anotación permite generar OCR, seleccionar el texto exacto y vincularlo con un campo, como se observa en la Figura 5.2.

Consola documental

Panel administrativo para definir documentos, revisar evidencias y controlar modelos OCR/NLP.

[Abrir analizador publico](#)
[Cerrar sesion](#)

01 Documento

02 Campos

03 Plantilla

04 **Anotacion**

05 Aprendizaje

06 Modelos

07 API

Constancia de servicio

Documento academico usado por la version inicial del sistema.

Campos
6

Documentos OCR
0

Lotes
0

Ultima decision
-

Vista Anotacion abierta.

Anotacion asistida

PDF

Seleccionar archivo

Sin archivos seleccionados

Preprocesamiento

Tesseract

Subir y generar OCR

Sube un PDF para generar OCR.

Selecciona un documento para revisar OCR.

Campo

Matricula (MATRICULA)

Texto seleccionado

Guardar anotacion

Vista Anotacion abierta.

Figura 5.2. Pantalla de anotación asistida.

Método	Uso recomendado
Tesseract	Opción predeterminada y ligera para PDFs escaneados o imágenes.
Docling	Alternativa para documentos cuya estructura requiera procesamiento avanzado, si está disponible.

Tabla 5.1. Métodos de preprocesamiento disponibles.

23. **Seleccione el PDF.** El archivo debe corresponder al tipo documental activo.
24. **Elija el preprocesamiento.** Use Tesseract salvo que exista una decisión técnica distinta.
25. **Seleccione Subir y generar OCR.** El documento aparecerá en la lista de evidencias.
26. **Seleccione el fragmento exacto.** No incluya etiquetas, espacios o texto del campo siguiente.
27. **Elija el campo y guarde.** Repita para cada entidad que deba enseñarse al modelo.

6 | Aprendizaje, lotes y modelos

Los documentos validados se acumulan por tipo documental. Un lote listo puede entrenar un candidato que debe evaluarse antes de su activación.

6.1 Lotes de entrenamiento

La etapa Aprendizaje resume el ciclo de cinco fases y muestra los lotes disponibles, como se observa en la Figura 6.1.




Figura 6.1. Seguimiento de lotes de entrenamiento.

Etapa	Resultado esperado
1. Recibir	PDF y campos corregidos registrados.
2. Acumular	Lote alcanza el umbral configurado.
3. Entrenar	Celery procesa el lote mediante el worker.
4. Evaluar	Métricas calculadas campo por campo.
5. Activar	El candidato se publica solo si no empeora el desempeño.

Tabla 6.1. Etapas del aprendizaje documental.

6.2 Versiones de modelo

La etapa Modelos muestra las versiones registradas y permite registrar un candidato, como se observa en la Figura 6.2.

Consola documental
Panel administrativo para definir documentos, revisar evidencias y controlar modelos OCR/NLP.

[Abrir analizador publico](#)
[Cerrar sesion](#)

- 01 Documento
- 02 Campos
- 03 Plantilla
- 04 Anotacion
- 05 Aprendizaje
- 06 Modelos**
- 07 API

Constancia de servicio

Documento academico usado por la version inicial del sistema.

Estado: activo Modelo: spacy_model

Campos 6	Documentos OCR 0	Lotes 0	Ultima decision -
--------------------	----------------------------	-------------------	-----------------------------

Vista Modelos abierta.

Versiones de modelo

Sin versiones registradas.

Nombre modelo	Ruta modelo
Documentos usados 0	F1 entidades
☐	

Activar como modelo en produccion

Observaciones

Registrar modelo

Vista Modelos abierta.

Figura 6.2. Registro y consulta de versiones de modelo.

28. **Capture el nombre y la ruta.** Use valores que permitan localizar el artefacto entrenado.
29. **Registre el volumen de entrenamiento.** Indique cuántos documentos sustentan la versión.
30. **Capture la métrica F1.** Use un valor entre 0 y 1 calculado sobre evaluación válida.
31. **Agregue observaciones.** Documente origen, cambios y limitaciones.
32. **Active solo después de comparar.** La opción de producción cambia el modelo utilizado por el tipo documental.

ADVERTENCIA

Activar un modelo sin evaluación confiable puede afectar todas las extracciones del tipo documental seleccionado.

7 Claves e integración API

La integración permite extraer documentos y devolver correcciones validadas. El acceso se protege mediante la cabecera 'X-API-Key' cuando existen claves activas.

7.1 Generar una clave

En la etapa API escriba el nombre de la integración y seleccione Generar API key. La pantalla se muestra en la Figura 7.1.




Figura 7.1. Panel de conexión y ejemplos de API.

33. **Escriba el nombre de la integración.** Use un nombre que identifique al sistema consumidor.

34. **Revise el permiso.** La versión actual ofrece extracción y aprendizaje.

35. **Genere la clave.** Copie el valor en ese momento y guárdelo en un gestor de secretos.

ADVERTENCIA

Una API key concede acceso persistente. No la incluya en código fuente, capturas, documentación pública ni registros sin protección.

7.2 Endpoints

Método	Endpoint	Propósito
GET	/tipos-documento	Consultar tipos, campos y estado.

Método	Endpoint	Propósito
POST	/extract	Enviar un PDF y obtener los campos extraídos.
POST	/aprendizaje/documentos-validados	Enviar un PDF con correcciones confirmadas.

Tabla 7.1. Endpoints principales de integración.

7.3 Solicitud de extracción

Envíe una solicitud `multipart/form-data` con el archivo, el identificador del tipo documental y la cabecera de autenticación cuando corresponda.

```
curl -X POST "http://HOST/extract" \
+ -H "X-API-Key: TU_API_KEY" \
+ -F "id_tipo_documento=constancia_servicio" \
+ -F "file=@constancia.pdf"
```

7.4 Envío de correcciones

El campo `campos\_validados` debe contener JSON válido. Incluya todos los campos obligatorios definidos para el tipo documental.

IMPORTANTE

Las correcciones alimentan lotes de aprendizaje. Envíe únicamente valores revisados por una persona responsable.

8 Solución de problemas y buenas prácticas

Los problemas más frecuentes se relacionan con archivos inválidos, credenciales, configuración incompleta, OCR deficiente o servicios auxiliares no disponibles.

8.1 Diagnóstico rápido

Situación	Causa probable	Acción
No abre la consola	Sesión inexistente o credencial incorrecta.	Regrese a `/login` y valide la credencial vigente.
El PDF no se procesa	Archivo vacío, dañado o con formato distinto.	Abra el PDF localmente y cargue una copia válida.
Faltan campos	Tipo incorrecto, OCR insuficiente o modelo sin evidencia.	Revise tipo, calidad, plantilla y anotaciones.
No hay lotes	No se han recibido documentos validados.	Verifique el endpoint de aprendizaje y la API key.
El entrenamiento no inicia	Worker Celery o Redis no disponible.	Solicite revisión del servicio y sus registros.
La API responde 401	Clave ausente, inválida o inactiva.	Envíe `X-API-Key` y verifique la clave en la consola.
La API responde 400	Falta archivo, tipo o campos obligatorios.	Revise nombres y contenido del formulario.

Tabla 8.1. Problemas frecuentes y acciones recomendadas.

8.2 Buenas prácticas operativas

- Mantenga los tipos en Borrador hasta completar pruebas representativas.
- Use un conjunto de evaluación separado del entrenamiento.
- Documente cada versión de modelo y su comparación.
- Rote credenciales comprometidas y almacene secretos fuera del repositorio.
- Revise la disponibilidad del servicio web, Redis y Celery antes de investigar el modelo.

8.3 Cierre de sesión

Seleccione Cerrar sesión al terminar una tarea administrativa, especialmente en equipos compartidos. El sistema volverá al formulario de acceso.

9 | Glosario y referencias

Esta sección reúne conceptos operativos y fuentes internas para facilitar el mantenimiento del sistema y del propio manual.

9.1 Glosario

Término	Definición
Anotación	Relación entre un fragmento exacto de OCR y un campo o entidad.
Campo obligatorio	Dato requerido para aceptar una validación documental.
Documento validado	PDF acompañado por valores corregidos y confirmados.
Lote	Conjunto de documentos utilizado para entrenamiento y evaluación.
Modelo activo	Versión utilizada en producción para un tipo documental.
Plantilla	Mapa aprendido de texto, posición y contexto para un formato repetible.
Tipo documental	Configuración que agrupa campos, plantillas, evidencias y modelos.

Tabla 9.1. Glosario operativo.

9.2 Referencias técnicas

- Código y configuración del proyecto `document\_processor`.
- Interfaz desplegada en AWS EC2 verificada el 25 de agosto de 2026.
- Guía interna de despliegue en VM y catálogo documental MySQL.
- Manual de usuario de referencia visual proporcionado para este proyecto.

NOTA

Las rutas, nombres de servicios y credenciales pertenecen a la operación técnica y no deben publicarse en versiones de distribución abierta.